

測度論から確率論へ

確率変数・収束・確率過程・応用までの見取り図

今日のゴール

測度論の言葉で確率論を読み替え、確率論でよく出てくる対象の位置づけをつかむ。

前半

- 確率空間と確率変数
- 分布と期待値
- 独立性
- 4種類の収束
- 大数の法則と中心極限定理

後半

- 確率過程
- Poisson過程
- Brown運動とMarkov性
- 条件付き期待値とMartingale
- 伊藤の公式の入口
- Black-Scholesと最適戦略

1. 測度論から確率論へ

確率空間

測度空間 $(\Omega, \mathcal{F}, P)$ が以下を満たすとき、**確率空間** と呼ぶ。

$$P(\Omega) = 1$$

記号	確率論での読み方
Ω	標本空間
$\omega \in \Omega$	標本、実現値
$A \in \mathcal{F}$	事象
$P(A)$	事象 A の確率

測度論の a.e. は、確率論では a.s. と呼ぶ。 $\mathcal{F}$ は「観測・判定できる事象の集まり」と見ると、後の filtration とつながりやすい。

確率測度の具体例

同じ「測度と積分」の形で、離散分布と連続分布を見ておく。

離散: 二項分布

$X \sim \text{Bin}(n, p)$ とする。

$$\Omega = \{0, 1, \dots, n\}, \quad \mathcal{F} = 2^\Omega$$

$$P(\{k\}) = \binom{n}{k} p^k (1-p)^{n-k}$$

関数 $f : \Omega \rightarrow \mathbb{R}$ の積分は

$$\int_{\Omega} f \, dP = \sum_{k=0}^n f(k) P(\{k\})$$

連続: 正規分布

$X \sim N(\mu, \sigma^2)$ とする。

$$\Omega = \mathbb{R}, \quad \mathcal{F} = \mathcal{B}(\mathbb{R})$$

$$P(A) = \int_A \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx$$

関数 $f : \mathbb{R} \rightarrow \mathbb{R}$ の積分は

$$\int_{\mathbb{R}} f \, dP = \int_{\mathbb{R}} f(x) \varphi_{\mu, \sigma}(x) \, dx$$

確率変数

実数値確率変数とは、可測写像

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$$

のこと。

定義の読み方

要素	意味
Ω	起こりうる全ての標本
$X(\omega)$	標本から取り出した数値
可測性	$X \in B$ の確率を定義できる条件

確率変数は「ランダムな値」ではなく、標本から観測量を取り出す写像。

分布

確率変数 X により、値域側に新しい確率測度を定義できる。

$$P_X(A) = P(X^{-1}(A)) = P(\{\omega \in \Omega : X(\omega) \in A\})$$

これを X の **分布** という。

$$(\Omega, \mathcal{F}, P) \xrightarrow{X} (S, \mathcal{S}, P_X)$$

測度論では pushforward measure と呼ぶ考え方。確率論では「 X の分布」と呼ぶことが多い。

期待値

可積分な確率変数 X に対して、

$$E[X] = \int_{\Omega} X(\omega) P(d\omega)$$

と定義する。

分布 P_X を使えば、Borel可測な f に対して

$$E[f(X)] = \int_S f(x) P_X(dx)$$

と書ける。

測度論での積分が、そのまま期待値になる。確率論固有の記法に見えて、中身は Lebesgue 積分。

生成する σ 加法族

確率変数 X が生成する σ 加法族は

$$\sigma(X) = \{X^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\}$$

を含む最小の σ 加法族。

X を観測して判別できる事象の全体。

例: 2回のコイントスを「1回でも表が出たか」だけで見る

標本空間を $\Omega = \{0, 1\}^2$ 、 $X(\omega) = \max(\omega_1, \omega_2)$ とする。

$$A_0 = X^{-1}(\{0\}) = \{(0, 0)\}, \quad A_1 = X^{-1}(\{1\}) = \{(0, 1), (1, 0), (1, 1)\}$$

$$\sigma(X) = \{\emptyset, A_0, A_1, \Omega\}$$

$(0, 1), (1, 0), (1, 1)$ は $X = 1$ としか見えないので区別できない。

生成する σ 加法族は、後で filtration を「時刻 t までに分かる情報」と読むための土台になる。

独立性

事象 A, B が独立とは

$$P(A \cap B) = P(A)P(B)$$

であること。

部分 σ 加法族 $\mathcal{G}, \mathcal{H} \subset \mathcal{F}$ が独立とは、

$$P(G \cap H) = P(G)P(H) \quad (G \in \mathcal{G}, H \in \mathcal{H})$$

が成り立つこと。

確率変数 X, Y が独立とは、

$$\sigma(X) \text{ と } \sigma(Y)$$

が独立であること。

「値が無関係」という直感を、可測集合全体の積構造として定式化している。

2. 収束概念

確率変数列の4つの収束

同じ確率空間上の確率変数列 X_n と X を考える。

収束	定義	見方
概収束	$X_n \rightarrow X \text{ a.s.}$	標本ごとに見る
確率収束	$P(X_n - X > \varepsilon) \rightarrow 0$	外れる確率を見る
L^p 収束	$E[X_n - X ^p] \rightarrow 0$	距離の平均を見る
法則収束	$P_{X_n} \Rightarrow P_X$	分布だけを見る

法則収束は分布だけを見る。 X_n と X が同一の確率空間上にある必要はない。

法則収束と弱収束

法則収束とは、確率変数の分布が弱収束すること。

$$X_n \Rightarrow X \iff P_{X_n} \Rightarrow P_X$$

関数で見る

任意の有界連続関数 f に対して

$$\int f dP_{X_n} \rightarrow \int f dP_X$$

すなわち

$$E[f(X_n)] \rightarrow E[f(X)]$$

分布関数で見る

実数値の場合、 F_X の連続点 x で

$$F_{X_n}(x) \rightarrow F_X(x)$$

と同値。

中心極限定理は、この意味で正規分布へ近づくことを述べる。

収束概念の関係

基本的な含意関係は次の通り。

$$\left. \begin{array}{l} L^p \text{収束} \\ \text{概収束} \end{array} \right\} \Rightarrow \text{確率収束} \Rightarrow \text{法則収束}$$

上にあるほど、同じ標本空間上で強い比較をしている。右へ行くほど分布だけを見る話になる。

3. 大数の法則と中心極限定理

大数の法則

$X_1, X_2, \dots$ を独立同分布、 $E[|X_1|] < \infty$ とする。

標本平均

$$\overline{X}_n = \frac{1}{n} \sum_{k=1}^n X_k$$

は、期待値 $m = E[X_1]$ に近づく。

弱法則

$$\overline{X}_n \rightarrow m$$

in probability

各 n で外れる確率が小さくなる。

$$P(|\overline{X}_n - m| > \varepsilon) \rightarrow 0$$

強法則

$$\overline{X}_n \rightarrow m$$

almost surely

ほとんどすべての標本列で、最終的に平均が近づく。

$$P\left(\lim_{n \rightarrow \infty} \overline{X}_n = m\right) = 1$$

大数の法則の直感

個々の試行は揺らぐが、平均を取ると揺らぎがならされる。

サイコロの平均

サイコロを何度も振ると、出目の平均は 3.5 に近づく。

$$\overline{X}_n = \frac{1}{n} \sum_{k=1}^n X_k$$

ただし、有限回では当然ぶれる。

分散有限なら

$$\text{Var}(\overline{X}_n) = \frac{\text{Var}(X_1)}{n}$$

これは定理そのものではなく、平均のばらつきが小さくなる直感を与える式。

中心極限定理

$X_1, X_2, \dots$ を独立同分布、 $E[X_1] = m$ 、 $\text{Var}(X_1) = \sigma^2 < \infty$ とする。

標本平均の揺らぎを $\sqrt{n}$ 倍して見ると、

$$\sqrt{n} \frac{\bar{X}_n - m}{\sigma} \Rightarrow N(0, 1)$$

すなわち、標準化した標本平均が標準正規分布へ **法則収束** する。

平均そのものは m に近づく。一方、 $\sqrt{n}$ 倍して揺らぎを拡大すると、極限分布として正規分布が現れる。

大数の法則と中心極限定理の違い

定理	見ているもの	結論
大数の法則	平均の極限	定数 m へ収束
中心極限定理	平均の揺らぎ	正規分布へ法則収束

$$\overline{X}_n \rightarrow m$$

$$\sqrt{n} \frac{\overline{X}_n - m}{\sigma} \Rightarrow N(0, 1)$$

「平均が収束する」と「収束の周りの揺らぎがどう見えるか」は別の問い。

4. 確率過程

確率過程

確率過程とは、時間 t をパラメータにもつ確率変数の族。

$$X = (X_t)_{t \geq 0}$$

各 t に対して

$$X_t : \Omega \rightarrow \mathbb{R}^d$$

が確率変数である。

ω を固定すると $t \mapsto X_t(\omega)$ という関数が得られる。これを標本路という。

経路値確率変数として見る

連続な標本路を持つ過程なら、

$$X : \Omega \rightarrow C([0, \infty), \mathbb{R}^d)$$

という関数空間値確率変数として見られる。

$$\omega \longmapsto (X_t(\omega))_{t \geq 0}$$

確率過程は「時間ごとの確率変数の族」でもあり、「ランダムな関数」でもある。

可測性と適合性

まず、時刻とともに情報が増える状況を

$$(\mathcal{F}_t)_{t \geq 0}, \quad \mathcal{F}_s \subseteq \mathcal{F}_t \ (s \leq t)$$

で表す。これを **filtration**、または情報増大系という。

概念	意味
適合性	X_t が $\mathcal{F}_t$ 可測
可測性	$(t, \omega) \mapsto X_t(\omega)$ が直積空間上で可測

例: 株価 S_t を時刻 t まで観測しているなら、 $\mathcal{F}_t$ は「時刻 t までの株価から分かる事象」の集まり。

情報増大系の例

サイコロを2回振る。標本空間は $\Omega = \{1, \dots, 6\}^2$ とする。

時刻1

1回目だけ見える。

$$\mathcal{F}_1 = \sigma(\omega_1)$$

この時点では、2回目の出目はまだ区別できない。

時刻2

2回目まで見える。

$$\mathcal{F}_2 = \sigma(\omega_1, \omega_2)$$

$$\mathcal{F}_1 \subseteq \mathcal{F}_2$$

情報は時間とともに増える。

条件付き期待値

部分 σ 加法族 $\mathcal{G} \subset \mathcal{F}$ に対する条件付き期待値

$$E[X \mid \mathcal{G}]$$

は、 $\mathcal{G}$ の情報だけで作る X の予測値。

厳密には、 $\mathcal{G}$ 可測な確率変数 Y で、任意の $G \in \mathcal{G}$ に対して

$$\int_G Y dP = \int_G X dP$$

を満たすものを $E[X \mid \mathcal{G}]$ と書く。

補足: 事象で条件付ける場合

事象 A に対しては、 A が起きた世界だけで平均を取る。

$$E[X \mid A] = \frac{1}{P(A)} \int_A X dP \quad (P(A) > 0)$$

これは数値。

$E[X \mid \mathcal{G}]$ は $\mathcal{G}$ 可測な確率変数。

事象で条件付ける期待値は「その事象上での平均」。 σ 加法族で条件付ける期待値は「与えられた情報で作る予測値」。

条件付き期待値の例

2回サイコロを振る

独立なサイコロの出目を X_1, X_2 とし、

$$S_1 = X_1, \quad S_2 = X_1 + X_2$$

とする。

時刻1までの情報を

$$\mathcal{F}_1 = \sigma(X_1)$$

と書く。

1回目だけ見えている

1回目が1だと分かっているなら

$$E[S_2 \mid X_1 = 1] = 1 + E[X_2] = 4.5$$

確率変数として書けば

$$E[S_2 \mid \mathcal{F}_1] = E[X_1 + X_2 \mid \mathcal{F}_1] = X_1 + 3.5$$

これは $\mathcal{F}_1$ 可測。情報 $\mathcal{F}_1$ で区別できる値だけを使った予測になっている。

Poisson過程

Poisson過程 $(N_t)_{t \geq 0}$ は、ランダムな到着回数を数える過程。

強度 $\lambda > 0$ のPoisson過程では、

$$N_t - N_s \sim \text{Poisson}(\lambda(t - s))$$

かつ、互いに重ならない時間区間の増分は独立。

具体例

- コールセンターへの着信数
- 工場ラインの不良品発生数
- Webサイトへのアクセス数
- 放射性崩壊の観測数

時刻 t までの回数

$$P(N_t = k) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}$$

λ は単位時間あたりの平均発生回数。

Poisson過程と待ち時間

イベントの到着時刻を

$$0 < T_1 < T_2 < \dots$$

とする。

最初の待ち時間

最初のイベント発生時刻 T_1 の分布関数は

$$F_{T_1}(t) = P(T_1 \leq t) = P(N_t \geq 1) = 1 - e^{-\lambda t}$$

したがって、これは指数分布の分布関数になるので

$$T_1 \sim \text{Exp}(\lambda)$$

記憶なし性

指数分布は

$$P(T > s + t \mid T > s) = P(T > t)$$

を満たす。

「しばらく来ていないから、そろそろ来るはず」とはならない。

Wiener過程

Wiener過程、または1次元Brown運動 $(W_t)_{t \geq 0}$ は、次を満たす連続確率過程。

1. $W_0 = 0$ a.s.
2. 標本路 $t \mapsto W_t(\omega)$ は連続
3. $0 \leq s < t$ に対して $W_t - W_s \sim N(0, t - s)$
4. 重ならない時間区間の増分は独立

※連続な標本路を持つが、典型的には非常に荒く、有限変動でも微分可能でもない。

補足: Bernoulli列の和との関係

独立な $\xi_k \in \{-1, 1\}$ を用いたBernoulli列の和

$$W_t^{(n)} = \frac{1}{\sqrt{n}} \sum_{k=1}^{\lfloor nt \rfloor} \xi_k$$

の極限としても現れる。1ステップの大きさが $\sqrt{dt}$ なので、後で $(dW_t)^2 = dt$ という記号計算につながる。

Wiener測度

Brown運動は、経路空間

$$C_0([0, \infty), \mathbb{R})$$

上の確率測度としても理解できる。

この経路空間上で、座標過程

$$W_t(w) = w(t)$$

がBrown運動になるような確率測度をWiener測度という。

確率過程を「経路空間上の確率測度」と見る視点は、測度論的確率論の中心的な発想。

Markov性

Markov性は、未来の分布が現在だけで決まり、過去の詳細には依存しないという性質。

過程 (X_t) がMarkov性を持つなら、時刻 s までの情報 $\mathcal{F}_s$ を知っていても、未来の予測に必要なのは現在値 X_s 。

$$E[f(X_t) \mid \mathcal{F}_s] = \varphi_{s,t}(X_s) \quad (s \leq t)$$

つまり、条件付き期待値が X_s の関数として書ける。

例

Poisson過程では $E[N_t \mid \mathcal{F}_s] = N_s + \lambda(t - s)$ 。

Wiener過程では $E[W_t \mid \mathcal{F}_s] = W_s$ 。

どちらもMarkov性を持つ代表的な確率過程。

Martingale

情報増大系 $(\mathcal{F}_t)$ に適合した過程 (M_t) が **Martingale** とは、

$$E[|M_t|] < \infty$$

かつ $s \leq t$ に対して

$$E[M_t \mid \mathcal{F}_s] = M_s$$

を満たすこと。

Markov性との違い

Markov性は「未来の分布が現在で決まる」という性質。

Martingaleは「未来の条件付き期待値が現在値と一致する」という性質。

確率積分

左端評価で定義する

Wiener過程に沿う確率積分は、分割 $0 = t_0 < t_1 < \dots < t_n = T$ に対して

$$\int_0^T f(W_t) dW_t \approx \sum_i f(W_{t_i}) (W_{t_{i+1}} - W_{t_i})$$

の極限として定義する。

このとき $f(W_{t_i})$ は時刻 t_i までの情報で決まる値を使う。
未来を見ないことが重要。

特にWiener過程では、形式的に

$$(dW_t)^2 = dt$$

という計算規則を使う。二項ランダムウォークの拡散極限では、微小な揺らぎの2乗が分散 dt として残る。

補足: 右端評価との違い

通常のRiemann積分であれば区間内の任意の点による評価で値は変わらない。

しかし、 W_t の積分で右端評価を行うと

$$\begin{aligned} \sum_i W_{t_{i+1}} \Delta W_i &= \sum_i (W_{t_i} + \Delta W_i) \Delta W_i \\ &= \sum_i W_{t_i} \Delta W_i + \sum_i (\Delta W_i)^2 \\ &\rightarrow \int_0^T W_t dW_t + T \end{aligned}$$

となり、左端評価と T だけずれる。

これはWiener過程の二次変分

$$\sum_i (\Delta W_i)^2 \rightarrow T$$

に由来する。

伊藤の公式

過程 X_t が

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t$$

で動くとき、滑らかな関数 $f(t, x)$ に対して

$$df(t, X_t) = \partial_t f dt + \partial_x f dX_t + \frac{1}{2} \partial_{xx} f (dX_t)^2$$

と書ける。

通常の微分との違い

古典的な連鎖律なら1階微分だけでよい。

Brown運動では揺らぎの2乗が dt と同じ次数で残る。

記号計算の要点

$$(dW_t)^2 = dt, \quad dW_t dt = 0, \quad (dt)^2 = 0$$

というルールで2階微分項が残る。

確率微分方程式を解く

(1)

$$dX_t = \alpha dW_t \quad \Rightarrow \quad X_t = X_0 + \alpha W_t$$

(2)

$$dX_t = \beta W_t dW_t \quad \Rightarrow \quad X_t = X_0 + \frac{\beta}{2}(W_t^2 - t)$$

上記は実際に伊藤の公式を満たすことを確認できる。また、以下の計算でも得ることが可能。

$$\begin{aligned} X_t - X_0 &= \beta \sum_i W_{t_i} (W_{t_{i+1}} - W_{t_i}) \\ &= \frac{\beta}{2} \sum_i (W_{t_i} + W_{t_{i+1}} + W_{t_i} - W_{t_{i+1}}) (W_{t_{i+1}} - W_{t_i}) \\ &= \frac{\beta}{2} \sum_i (W_{t_{i+1}}^2 - W_{t_i}^2) - \frac{\beta}{2} \sum_i (W_{t_{i+1}} - W_{t_i})^2 \\ &= \frac{\beta}{2} W_t^2 - \frac{\beta}{2} t \end{aligned}$$

(3)

$$dX_t = \mu X_t dt + \sigma X_t dW_t$$

これは $Y_t = \log X_t$ と変数変換を行えば、伊藤の公式より

$$\begin{aligned} dY_t &= \frac{1}{X_t} dX_t - \frac{1}{2X_t^2} (dX_t)^2 \\ &= \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t \end{aligned}$$

したがって以下が成立

$$X_t = X_0 \exp \left[\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma W_t \right]$$

補足: 初期値

ここでは初期時刻を 0 とし、初期値を X_0 として書いている。

5. 応用

Black-Scholesモデル

株価 S_t を幾何Brown運動でモデル化する。

$$dS_t = \mu S_t dt + \sigma S_t dW_t$$

形式的には、微小な投資リターン dS_t/S_t が正規分布するモデルと見られる。

$$\frac{dS_t}{S_t} \sim N(\mu dt, \sigma^2 dt)$$

このとき前述の確率微分方程式より

$$S_t = S_0 \exp \left[\left(\mu - \frac{\sigma^2}{2} \right) t + \sigma W_t \right]$$

このとき S_t の期待値は

$$E[S_t] = S_0 e^{\mu t}$$

オプションとは何か

オプションは、将来の時点で資産を売買する **権利**。

義務ではない。

コールオプション

満期 T に、株を価格 K で買う権利。

満期の価値は

$$(S_T - K)^+$$

直感

$S_T > K$ なら、安く買えるので得をする。

$S_T \leq K$ なら、権利を行使しない。

損失は最初に払うプレミアムに限られる。

オプション価格の算出

時刻 t のオプション価格 V_t が安全資産 B_t と原資産 S_t の組み合わせで表現可能とする。

$$V_t = p_t B_t + q_t S_t$$

このとき、オプション価格の変動は以下となる。

$$dV_t = p_t dB_t + q_t dS_t + \underline{B_t dp_t + S_t dq_t}$$

特に、新たな資金の流入・流出がないことを仮定すると下線部については各資産のポジションの組み替えを意味するから0となる。

ここで、安全資産 B_t はリスクフリーレート r を用いて $B_t = B_0 e^{rt}$ 、 S_t がBlack-Scholes過程に準ずるとすると

$$dV_t = (rp_t B_t + \mu q_t S_t) dt + \sigma q_t S_t dW_t$$

一方、 V_t を原資産 S_t による確率過程と解釈して $V_t = V(t, S_t)$ と扱うと伊藤の公式より

$$dV_t = \left(\partial_t V_t + \mu S_t \partial_S V_t + \frac{\sigma^2}{2} S_t^2 \partial_{SS} V_t \right) dt + \sigma S_t \partial_S V_t dW_t$$

これら2式の dt 項、 dW_t 項の比較および $V_t = p_t B_t + q_t S_t$ を利用して整理すると


$$\partial_t V + \frac{1}{2} \sigma^2 S^2 \partial_{SS} V + r S \partial_S V - r V = 0$$

これを、終端条件 $V(T, S) = (S - K)^+$ のもとで解くと

$$V(t, S) = S \Phi(d_1) - K e^{-r(T-t)} \Phi(d_2)$$

$$d_1 = \frac{\log(S/K) + (r + \sigma^2/2)(T-t)}{\sigma \sqrt{T-t}}, \quad d_2 = d_1 - \sigma \sqrt{T-t}, \quad \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{\xi^2}{2}} d\xi$$

オプション価格のグラフ



最適戦略

確率論では、ランダムな状況のもとで最適な意思決定を考える。

典型例:

- サイコロを振り直すか止めるか
- 秘書問題
- 停止時刻
- 動的計画法

最適停止とMartingale

ある時刻で止めるルールを停止時刻という。

情報増大系 $(\mathcal{F}_t)$ に対して、すべての t で

$$\{\tau \leq t\} \in \mathcal{F}_t$$

なら、時刻 t までの情報だけで「もう止めたか」を判定できる。

Martingale (M_t) に対しては、条件を満たす停止時刻 τ で

$$E[M_\tau] = E[M_0]$$

となる。これを任意停止定理という。

公平なゲームでは、止め方だけを工夫しても期待値は増やせない、という主張。

例: 停止時刻とそうでないもの

サイコロの出目を $X_1, X_2, \dots$ 、時刻 n までの情報を $\mathcal{F}_n$ とする。

停止時刻:

$$\tau = \inf\{n \mid X_n = 6\}$$

時刻 n までに6が出たかは、時刻 n までの出目だけで判定できる。

停止時刻でない例:

$$\tau = \begin{cases} 1 & (X_2 = 6) \\ 2 & (X_2 \neq 6) \end{cases}$$

$\{\tau \leq 1\} = \{X_2 = 6\}$ は、時刻1の情報 $\mathcal{F}_1$ では判定できない。

戦略の例

サイコロの停止問題

最大 n 回まで振れる。各回で止めるか続けるかを決める。

$$V_k = E[\max(D, V_{k-1})]$$

動的計画法で「今止める価値」と「続ける価値」を比べる。

秘書問題

n 人を順番に見て、その場で採用するか見送る。

古典的には

最初の約 n/e 人を見送り、その後の暫定1位を採用

INTERACTIVE SUPPLEMENT

最適戦略シミュレータ

DISABLED

PDF版では利用できません。Web版からお試しください。

最適戦略は細かく解くより、情報が増える中で止める時刻を選ぶ問題として紹介する。

6. まとめ

全体像

測度論 → 確率空間 → 確率変数 → 分布 → 収束 → 確率過程 →
条件付き期待値 → Martingale → 応用

今日の主眼は、個々の定理を証明し切るのではなく、測度論の言葉が確率論のどこで効くかを見えるようにすること。

参考文献

- 熊谷隆『確率論』
- 舟木直久『確率微分方程式』
- Alcia Solid Project「確率微分方程式」シリーズ動画