

測度論から確率論へ

確率変数・収束・確率過程・応用までの見取り図

40-60分想定 / 測度論・Lebesgue積分の概論後

今日のゴール

測度論の言葉で確率論を読み替え、確率論でよく出てくる対象の位置づけをつかむ。

前半

- 確率空間と確率変数
- 分布と期待値
- 独立性
- 4種類の収束
- 大数の法則と中心極限定理

後半

- 確率過程
- Poisson過程
- Brown運動とMarkov性
- 条件付き期待値とMartingale
- 伊藤の公式の入口
- Black-Scholesと最適戦略

時間配分

PDFとして読んでも流れが追えるように、定義はやや明示的に残す。

パート	内容	目安
1	確率空間・確率変数・分布	8分
2	独立性・期待値・収束概念	12分
3	大数の法則・中心極限定理	8分
4	確率過程・条件付き期待値・Martingale	15分
5	伊藤の公式・Black-Scholes・最適戦略	12分
6	まとめ・議論	5分

1. 測度論から確率論へ

確率空間

測度空間 $(\Omega, \mathcal{F}, P)$ が以下を満たすとき、**確率空間** と呼ぶ。

$$P(\Omega) = 1$$

記号	確率論での読み方
Ω	標本空間
$\omega \in \Omega$	標本、実現値
$A \in \mathcal{F}$	事象
$P(A)$	事象 A の確率

測度論の a.e. は、確率論では a.s. と呼ぶ。 $\mathcal{F}$ は「観測・判定できる事象の集まり」と見ると、後の filtration とつながりやすい。

確率測度の具体例

同じ「測度と積分」の形で、離散分布と連続分布を見ておく。

離散: 二項分布

$X \sim \text{Bin}(n, p)$ とする。

$$\Omega = \{0, 1, \dots, n\}, \quad \mathcal{F} = 2^\Omega$$

$$P(\{k\}) = \binom{n}{k} p^k (1-p)^{n-k}$$

関数 $f: \Omega \rightarrow \mathbb{R}$ の積分は

$$\int_{\Omega} f \, dP = \sum_{k=0}^n f(k) P(\{k\})$$

連続: 正規分布

$X \sim N(\mu, \sigma^2)$ とする。

$$\Omega = \mathbb{R}, \quad \mathcal{F} = \mathcal{B}(\mathbb{R})$$

$$P(A) = \int_A \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx$$

関数 $f: \mathbb{R} \rightarrow \mathbb{R}$ の積分は

$$\int_{\mathbb{R}} f \, dP = \int_{\mathbb{R}} f(x) \varphi_{\mu, \sigma}(x) \, dx$$

確率変数

実数値確率変数とは、可測写像

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$$

のこと。

定義の読み方

要素	意味
Ω	起こりうる全ての標本
$X(\omega)$	標本から取り出した数値
可測性	$X \in B$ の確率を定義できる条件

例: サイコロ2個の合計を見る

サイコロ2個を振る。

$$\Omega = \{1, \dots, 6\}^2$$

合計を見るなら

$$X(\omega_1, \omega_2) = \omega_1 + \omega_2$$

同じ合計になる出方は、 X だけを見ると区別しない。

確率変数は「ランダムな値」ではなく、標本から観測量を取り出す写像。

分布

確率変数 X により、値域側に新しい確率測度を定義できる。

$$P_X(A) = P(X^{-1}(A)) = P(\{\omega \in \Omega : X(\omega) \in A\})$$

これを X の **分布** という。

$$(\Omega, \mathcal{F}, P) \xrightarrow{X} (S, \mathcal{S}, P_X)$$

測度論では pushforward measure と呼ぶ考え方。確率論では「 X の分布」と呼ぶことが多い。

期待値

可積分な確率変数 X に対して、

$$E[X] = \int_{\Omega} X(\omega) P(d\omega)$$

と定義する。

分布 P_X を使えば、Borel可測な f に対して

$$E[f(X)] = \int_S f(x) P_X(dx)$$

と書ける。

測度論での積分が、そのまま期待値になる。確率論固有の記法に見えて、中身は Lebesgue 積分。

生成する σ 加法族

確率変数 X が生成する σ 加法族は

$$\sigma(X) = \{X^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\}$$

を含む最小の σ 加法族。

X を観測して判別できる事象の全体。

例: 2回のコイントスを「1回でも表が出たか」だけで見る

標本空間を $\Omega = \{0, 1\}^2$ 、 $X(\omega) = \max(\omega_1, \omega_2)$ とする。

$$A_0 = X^{-1}(\{0\}) = \{(0, 0)\}, \quad A_1 = X^{-1}(\{1\}) = \{(0, 1), (1, 0), (1, 1)\}$$

$$\sigma(X) = \{\emptyset, A_0, A_1, \Omega\}$$

$(0, 1), (1, 0), (1, 1)$ は $X = 1$ としか見えないので区別できない。

生成する σ 加法族は、後で filtration を「時刻 t までに分かる情報」と読むための土台になる。

独立性

事象 A, B が独立とは

$$P(A \cap B) = P(A)P(B)$$

であること。

部分 σ 加法族 $\mathcal{G}, \mathcal{H} \subset \mathcal{F}$ が独立とは、

$$P(G \cap H) = P(G)P(H) \quad (G \in \mathcal{G}, H \in \mathcal{H})$$

が成り立つこと。

確率変数 X, Y が独立とは、

$$\sigma(X) \text{ と } \sigma(Y)$$

が独立であること。

「値が無関係」という直感を、可測集合全体の積構造として定式化している。

2. 収束概念

確率変数列の4つの収束

同じ確率空間上の確率変数列 X_n と X を考える。

収束	定義	見方
概収束	$X_n \rightarrow X \text{ a.s.}$	標本ごとに見る
確率収束	$P(X_n - X > \varepsilon) \rightarrow 0$	外れる確率を見る
L^p 収束	$E[X_n - X ^p] \rightarrow 0$	距離の平均を見る
法則収束	$P_{X_n} \Rightarrow P_X$	分布だけを見る

法則収束は分布だけを見る。 X_n と X が同一の確率空間上にある必要はない。

法則収束と弱収束

法則収束とは、確率変数の分布が弱収束すること。

$$X_n \Rightarrow X \iff P_{X_n} \Rightarrow P_X$$

関数で見る

任意の有界連続関数 f に対して

$$\int f dP_{X_n} \rightarrow \int f dP_X$$

すなわち

$$E[f(X_n)] \rightarrow E[f(X)]$$

分布関数で見る

実数値の場合、 F_X の連続点 x で

$$F_{X_n}(x) \rightarrow F_X(x)$$

と同値。

中心極限定理は、この意味で正規分布へ近づくことを述べる。

収束概念の関係

基本的な含意関係は次の通り。

$$\left. \begin{array}{l} L^p \text{収束} \\ \text{概収束} \end{array} \right\} \Rightarrow \text{確率収束} \Rightarrow \text{法則収束}$$

上にあるほど、同じ標本空間上で強い比較をしている。右へ行くほど分布だけを見る話になる。

3. 大数の法則と中心極限定理

大数の法則

$X_1, X_2, \dots$ を独立同分布、 $E[|X_1|] < \infty$ とする。

標本平均

$$\overline{X}_n = \frac{1}{n} \sum_{k=1}^n X_k$$

は、期待値 $m = E[X_1]$ に近づく。

弱法則

$$\overline{X}_n \rightarrow m$$

in probability

各 n で外れる確率が小さくなる。

$$P(|\overline{X}_n - m| > \varepsilon) \rightarrow 0$$

強法則

$$\overline{X}_n \rightarrow m$$

almost surely

ほとんどすべての標本列で、最終的に平均が近づく。

$$P\left(\lim_{n \rightarrow \infty} \overline{X}_n = m\right) = 1$$

大数の法則の直感

個々の試行は揺らぐが、平均を取ると揺らぎがならされる。

サイコロの平均

サイコロを何度も振ると、出目の平均は 3.5 に近づく。

$$\overline{X}_n = \frac{1}{n} \sum_{k=1}^n X_k$$

ただし、有限回では当然ぶれる。

分散有限なら

$$\text{Var}(\overline{X}_n) = \frac{\text{Var}(X_1)}{n}$$

これは定理そのものではなく、平均のばらつきが小さくなる直感を与える式。

中心極限定理

$X_1, X_2, \dots$ を独立同分布、 $E[X_1] = m$ 、 $\text{Var}(X_1) = \sigma^2 < \infty$ とする。

標本平均の揺らぎを $\sqrt{n}$ 倍して見ると、

$$\sqrt{n} \frac{\bar{X}_n - m}{\sigma} \Rightarrow N(0, 1)$$

すなわち、標準化した標本平均が標準正規分布へ **法則収束** する。

平均そのものは m に近づく。一方、 $\sqrt{n}$ 倍して揺らぎを拡大すると、極限分布として正規分布が現れる。

大数の法則と中心極限定理の違い

定理	見ているもの	結論
大数の法則	平均の極限	定数 m へ収束
中心極限定理	平均の揺らぎ	正規分布へ法則収束

$$\overline{X}_n \rightarrow m$$

$$\sqrt{n} \frac{\overline{X}_n - m}{\sigma} \Rightarrow N(0, 1)$$

「平均が収束する」と「収束の周りの揺らぎがどう見えるか」は別の問い。

4. 確率過程

確率過程

確率過程とは、時間 t をパラメータにもつ確率変数の族。

$$X = (X_t)_{t \geq 0}$$

各 t に対して

$$X_t : \Omega \rightarrow \mathbb{R}^d$$

が確率変数である。

ω を固定すると $t \mapsto X_t(\omega)$ という関数が得られる。これを標本路という。

経路値確率変数として見る

連続な標本路を持つ過程なら、

$$X : \Omega \rightarrow C([0, \infty), \mathbb{R}^d)$$

という関数空間値確率変数として見られる。

$$\omega \longmapsto (X_t(\omega))_{t \geq 0}$$

確率過程は「時間ごとの確率変数の族」でもあり、「ランダムな関数」でもある。

可測性と適合性

まず、時刻とともに情報が増える状況を

$$(\mathcal{F}_t)_{t \geq 0}, \quad \mathcal{F}_s \subseteq \mathcal{F}_t \ (s \leq t)$$

で表す。これを **filtration**、または情報増大系という。

概念	意味
適合性	X_t が $\mathcal{F}_t$ 可測
可測性	$(t, \omega) \mapsto X_t(\omega)$ が直積空間上で可測

例: 株価 S_t を時刻 t まで観測しているなら、 $\mathcal{F}_t$ は「時刻 t までの株価から分かる事象」の集まり。

情報増大系の例

サイコロを2回振る。標本空間は $\Omega = \{1, \dots, 6\}^2$ とする。

時刻1

1回目だけ見える。

$$\mathcal{F}_1 = \sigma(\omega_1)$$

この時点では、2回目の出目はまだ区別できない。

時刻2

2回目まで見える。

$$\mathcal{F}_2 = \sigma(\omega_1, \omega_2)$$

$$\mathcal{F}_1 \subseteq \mathcal{F}_2$$

情報は時間とともに増える。

条件付き期待値

部分 σ 加法族 $\mathcal{G} \subset \mathcal{F}$ に対する条件付き期待値

$$E[X \mid \mathcal{G}]$$

は、 $\mathcal{G}$ の情報だけで作る X の予測値。

厳密には、 $\mathcal{G}$ 可測な確率変数 Y で、任意の $G \in \mathcal{G}$ に対して

$$\int_G Y \, dP = \int_G X \, dP$$

を満たすものを $E[X \mid \mathcal{G}]$ と書く。

条件付き期待値は「条件付き確率の平均版」というだけでなく、情報を粗くしたときの最良予測として働く。

条件付き期待値の見方

情報で粗く見る

$E[X \mid \mathcal{G}]$ は $\mathcal{G}$ 可測なので、 $\mathcal{G}$ で区別できない標本には同じ値を返す。

細かい未来の情報は使わず、今見える情報だけで平均を取る。

時間付きで見る

情報増大系 $(\mathcal{F}_t)$ に対して、

$$E[X \mid \mathcal{F}_t]$$

は「時刻 t までの情報から見た X の予測」。

金融では、将来ペイオフの現在時点での価値を表すときに現れる。

Poisson過程

Poisson過程 $(N_t)_{t \geq 0}$ は、ランダムな到着回数を数える過程。

強度 $\lambda > 0$ のPoisson過程では、

$$N_t - N_s \sim \text{Poisson}(\lambda(t - s))$$

かつ、互いに重ならない時間区間の増分は独立。

具体例

- コールセンターへの着信数
- 工場ラインの不良品発生数
- Webサイトへのアクセス数
- 放射性崩壊の観測数

時刻 t までの回数

$$P(N_t = k) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}$$

λ は単位時間あたりの平均発生回数。

Poisson過程と待ち時間

イベントの到着時刻を

$$0 < T_1 < T_2 < \dots$$

とする。

最初の待ち時間

$$P(T_1 > t) = P(N_t = 0) = e^{-\lambda t}$$

したがって

$$T_1 \sim \text{Exp}(\lambda)$$

記憶なし性

指数分布は

$$P(T > s + t \mid T > s) = P(T > t)$$

を満たす。

「しばらく来ていないから、そろそろ来るはず」とはならない。

Brown運動

1次元Brown運動、またはWiener過程 $(W_t)_{t \geq 0}$ は、次を満たす連続確率過程。

1. $W_0 = 0$ a.s.
2. 標本路 $t \mapsto W_t(\omega)$ は連続
3. $0 \leq s < t$ に対して $W_t - W_s \sim N(0, t - s)$
4. 重ならない時間区間の増分は独立

連続な標本路を持つが、典型的には非常に荒く、有限変動でも微分可能でもない。

Wiener測度

Brown運動は、経路空間

$$C_0([0, \infty), \mathbb{R})$$

上の確率測度としても理解できる。

この経路空間上で、座標過程

$$W_t(w) = w(t)$$

がBrown運動になるような確率測度をWiener測度という。

確率過程を「経路空間上の確率測度」と見る視点は、測度論的確率論の中心的な発想。

Markov性

Markov性は、未来の分布が現在だけで決まり、過去の詳細には依存しないという性質。

Brown運動では、

$$W_{t+s} - W_s$$

が $\mathcal{F}_s$ と独立で、分布は W_t と同じ。

条件付き期待値で書けば、

$$E[f(W_{t+s}) \mid \mathcal{F}_s] = E_{W_s}[f(W_t)]$$

Martingale

情報増大系 $(\mathcal{F}_t)$ に適合した過程 (M_t) が **Martingale** とは、

$$E[|M_t|] < \infty$$

かつ $s \leq t$ に対して

$$E[M_t \mid \mathcal{F}_s] = M_s$$

を満たすこと。

Markov性との違い

Markov性は「未来の分布が現在で決まる」という性質。

Martingaleは「未来の条件付き期待値が現在値と一致する」という性質。

例

独立な平均0の増分を足した

$$M_n = \sum_{k=1}^n \xi_k$$

は離散時間Martingale。

Wiener過程 (W_t) もMartingale。

伊藤積分は紹介に留める

Brown運動に沿った積分

$$\int_0^t H_s dW_s$$

は、普通のリーマン-Stieltjes積分としては扱いにくい。

Brown運動の標本路は連続だが、典型的には有界変動ではないため。

この勉強会では、伊藤積分の構成は深入りせず、次の2点だけ押さえる。

- 未来を見ない適合過程に対して定義される積分
- 伊藤の公式で、通常の微分公式とは違う2階微分項が現れる

伊藤の公式

過程 X_t が

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t$$

で動くとき、滑らかな関数 $f(t, x)$ に対して

$$df(t, X_t) = \partial_t f dt + \partial_x f dX_t + \frac{1}{2} \partial_{xx} f (dX_t)^2$$

と書ける。

通常の微分との違い

古典的な連鎖律なら1階微分だけでよい。

Brown運動では揺らぎの2乗が dt と同じ次数で残る。

記号計算の要点

$$(dW_t)^2 = dt, \quad dW_t dt = 0, \quad (dt)^2 = 0$$

というルールで2階微分項が残る。

2階微分項が残る意味

普通の滑らかな経路なら、微小変化の2乗は高次の小さい量として消える。

しかしBrown運動では、

$$W_{t+\Delta t} - W_t$$

の大きさが典型的に $\sqrt{\Delta t}$ 程度なので、2乗すると Δt 程度になる。

つまり、

$$(\Delta W)^2 \sim \Delta t$$

が極限で無視できず、伊藤の公式に

$$\frac{1}{2}\sigma^2\partial_{xx}f\,dt$$

が現れる。

金融工学では、この2階微分項がBlack-Scholes方程式のガンマ項につながる。

確率微分方程式の例

Brown運動に駆動される

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t$$

ドリフト項とランダムな揺らぎを持つ過程。

幾何Brown運動

$$dS_t = \mu S_t dt + \sigma S_t dW_t$$

金融で株価モデルとして使われる。相対変化率にノイズが入る形。

5. 応用

Black-Scholesモデル

株価 S_t を幾何Brown運動でモデル化する。

$$dS_t = \mu S_t dt + \sigma S_t dW_t$$

ここで、

記号	意味
μ	平均成長率
σ	ボラティリティ
W_t	Wiener過程

価格そのものではなく、相対変化率にランダムな揺らぎが入るモデル。

オプションとは何か

オプションは、将来の時点で資産を売買する **権利**。

義務ではない。

コールオプション

満期 T に、株を価格 K で買う権利。

満期の価値は

$$(S_T - K)^+$$

直感

$S_T > K$ なら、安く買えるので得をする。

$S_T \leq K$ なら、権利を行使しない。

損失は最初に払うプレミアムに限られる。

オプション価格

ヨーロピアン・コールオプションの満期 T でのペイオフは

$$(S_T - K)^+$$

ここで K は権利行使価格。

Black-Scholes理論では、無裁定の考え方から価格関数 $V(t, S)$ が満たす方程式を導く。

$$\partial_t V + \frac{1}{2} \sigma^2 S^2 \partial_{SS} V + rS \partial_S V - rV = 0$$

終端条件:

$$V(T, S) = (S - K)^+$$

Black-Scholesの見方

Black-Scholes方程式は、オプション価格を決めるPDE。

確率論側

リスク中立測度の下で

$$V(t, S) = e^{-r(T-t)} E[(S_T - K)^+ \mid S_t = S]$$

という条件付き期待値で価格を表す。

解析側

同じ価格関数 $V(t, S)$ は

$$\partial_t V + \frac{1}{2} \sigma^2 S^2 \partial_{SS} V + rS \partial_S V - rV = 0$$

を満たす。

確率過程とPDEが接続する。

何が確率論とつながるか

Black-Scholesは、次の概念が一気につながる例。

- Brown運動
- 確率微分方程式
- 伊藤の公式
- Markov性
- 偏微分方程式
- 条件付き期待値
- Martingale
- リスク中立測度

この勉強会では厳密な金融数学の完成より、「確率過程が解析と応用へ接続する」ことを見せる位置づけにする。

金融工学とMartingale

リスク中立測度 Q の下では、割引後の価格過程がMartingaleになる。

$$E^Q[e^{-rt}S_t \mid \mathcal{F}_s] = e^{-rs}S_s \quad (s \leq t)$$

価格づけの見方

将来ペイオフを割り引いた期待値が現在価格になる。

$$V_t = E^Q[e^{-r(T-t)}H \mid \mathcal{F}_t]$$

ここで効く概念

- 条件付き期待値
- filtration
- Martingale
- 伊藤の公式
- 無裁定

最適戦略

確率論では、ランダムな状況のもとで最適な意思決定を考える。

典型例:

- サイコロを振り直すか止めるか
- 秘書問題
- 停止時刻
- 動的計画法

「事前に全部見られない」「途中で止める必要がある」という状況では、情報の増え方が本質になる。

最適停止とMartingale

ある時刻で止めるルールを停止時刻という。

τ

は「時刻 τ までの情報だけで、止めたかどうかを判定できる」時刻。

Martingale (M_t) に対しては、条件を満たす停止時刻 τ で

$$E[M_\tau] = E[M_0]$$

となる。これを任意停止定理という。

公平なゲームでは、止め方だけを工夫しても期待値は増やせない、という主張。

戦略の例

サイコロの停止問題

最大 n 回まで振れる。各回で止めるか続けるかを決める。

$$V_k = E[\max(D, V_{k-1})]$$

動的計画法で「今止める価値」と「続ける価値」を比べる。

秘書問題

n 人を順番に見て、その場で採用するか見送る。

古典的には

最初の約 n/e 人を見送り、その後の暫定1位を採用

最適戦略は細かく解くより、情報が増える中で止める時刻を選ぶ問題として紹介する。

6. まとめ

全体像

測度論 → 確率空間 → 確率変数 → 分布 → 収束 → 確率過程 →
条件付き期待値 → Martingale → 応用

今日の主眼は、個々の定理を証明し切るのではなく、測度論の言葉が確率論のどこで効くかを見えるようにすること。

参考文献

- 熊谷隆『確率論』
- 舟木直久『確率微分方程式』
- Alcia Solid Project「確率微分方程式」シリーズ動画